

Universidade Federal de Minas Gerais  
Escola de Engenharia  
Programa de Pós-Graduação em Engenharia Elétrica  
Laboratório de Modelagem, Análise e Controle de Sistemas Não-Lineares

# FUSÃO SENSORIAL PARA SISTEMAS COM AMOSTRAGEM IRREGULAR

**Taiguara Melo Tupinambás**

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal de Minas Gerais como requisito parcial para a obtenção do grau de Mestre em Engenharia Elétrica

**Orientador:** Prof. Dr. Bruno Otávio Soares Teixeira

**Co-Orientador:** Prof. Dr. Leonardo Antônio Borges Tôrres

Belo Horizonte - MG

2018

## Sumário

<b>1</b>	<b>Introdução . . . . .</b>	<b>2</b>
1.1	<i>Motivação e Justificativa . . . . .</i>	2
1.2	<i>Formulação do problema . . . . .</i>	5
1.3	<i>Objetivos . . . . .</i>	5
1.4	<i>Estrutura da Dissertação . . . . .</i>	5
<b>2</b>	<b>Conclusão . . . . .</b>	<b>6</b>
	<b>Referências . . . . .</b>	<b>7</b>

## 1 Introdução

### 1.1 Motivação e Justificativa

Estimação é o processo de inferência do valor de uma quantidade de interesse a partir de observações incertas e, eventualmente, indiretas de outras variáveis (Bar-Shalom, Rong Li e Kirubarajan (2001)). Para o caso linear e Gaussiano, o filtro de Kalman (KF) garante otimalidade na estimação dos estados de um sistema dinâmico. Para sistemas não-lineares, generalizações do KF foram propostas, como por exemplo o filtro de Kalman estendido (EKF) e o filtro de Kalman *Unscented* (UKF). Métodos de filtragem de partículas podem ser aplicados para tratar sistemas não-lineares e não-Gaussianos (Teixeira (2008)).

Tanto os filtros de Kalman como os de Partícula utilizam modelos de processo e de observação em seus algoritmos. Bar-Shalom, Rong Li e Kirubarajan (2001) definem modelos de processo como o conjunto de uma estimativa inicial imperfeita e de uma evolução dos estados previsível e incerta, conforme Eq. 1.

$$(\text{estado})_{k+1} = (\text{função do estado})_k + (\text{ruído de processo})_k \quad (1)$$

onde  $k$  representa o índice de tempo discreto.

Já o modelo de medições engloba alguns componentes do espaço de estados (ou uma combinação deles) também de forma imprecisa, descrito pela Eq. 2.

$$(\text{medições})_k = (\text{função dos estados})_k + (\text{ruído de medição})_k \quad (2)$$

Tipicamente, funções de estado da Eq. 1 envolvem entradas que excitam o sistema dinâmico e que devem ser conhecidas. Em diversas aplicações práticas, como rastreamento de alvos, estas entradas são transmitidas para o sistema de filtragem através de sensores, da mesma forma que as observações.

Com o avanço científico das últimas décadas, a tecnologia de microprocessadores, de sensores e de comunicação tem ficado cada vez mais acessível e abrangente. Aliado a isso, o aumento exponencial na capacidade de processamento de computadores modernos faz com que seja possível a fusão de cada vez mais informações para sistemas de estimação em tempo real. Os benefícios para a estimação de estados da fusão de dados de múltiplos sensores em relação a dados de fonte única são óbvios. Além do ganho estatístico em se combinar dados redundantes de fontes iguais, ainda é possível obter estimativas mais precisas através do uso de vários tipos de sensores diferentes (Hall e Llinas (1997)).

A área de fusão sensorial já é pesquisada há vários anos e trabalhos como os de Hall e Llinas (1997), Khaleghi et al. (2013) e Jing, Pan e Qin (2013) trazem uma extensa revisão bibliográfica sobre o assunto. Willner, Chang e Dunn (1976) propõem três métodos de fusão sensorial para estimação de estados com a coleta de dados sincronizadas: i) método de filtragem paralela, que processa todas as medições concomitantemente na etapa de atualização do filtro; ii) método de filtragem sequencial, em que a atualização do filtro é feita de forma sequencial, i.e. a saída de um KF é utilizada como a previsão do estado do próximo KF; iii) método de compressão de dados (ou fusão das saídas), em que as observações são combinadas através da matriz de covariância de cada uma delas e o resultado dessa fusão é utilizado como medição única para o KF.

Por outro lado, a utilização de grande quantidade de sensores pode trazer desafios técnicos para o problema de filtragem. Redes de sensores dessincronizados, por exemplo, podem gerar observações com intervalos de tempo aleatórios, caracterizando uma amostragem irregular (Micheli e Jordan (2002)). Quando os sensores são transmitidos por vários subsistemas em uma rede, pode haver perda de pacotes, atrasos (Schenato et al. (2007)) ou até múltiplas informações chegando simultaneamente (Moayedi, Foo e Soh (2011)). Em sistemas embarcados que contam com grande integração de dados, mas restrições de energia, é possível optar pela amostragem baseada em eventos, que também gera irregularidade nos intervalos de tempo (Zou, Wang e Zhou (2017)). Quando dados de múltiplas plataformas são coletados e unidos de forma centralizada, as medições podem chegar fora de sequência (fenômeno conhecido como *out-of-sequence measurements*, i.e OOSM), devido a tempos diferentes de pré-processamento e atrasos nas redes de comunicação (Anxi et al. (2005))

Ou seja, apesar de oferecer grandes vantagens em relação à precisão das estimações de estado, a fusão sensorial de múltiplas fontes pode causar diversos problemas na amostragem dos sinais utilizados pelo filtro. Para lidar com este problema, alguns autores já trataram o problema no contexto de fusão sensorial. No trabalho de Fatehi e Huang (2017) é apresentado um método para estimação de estados de um sistema com observações oriundas de instrumentação *online* e de dados laboratoriais, modelo muito comum em processos industriais. O primeiro conjunto de observações possui alta frequência de amostragem, é regular, sem atrasos, mas incerto. Por outro lado, dados medidos em laboratórios são de baixa frequência de amostragem, irregulares, com atraso, mas muito mais precisos. Gopalakrishnan, Kaisare e Narasimhan (2010) apresentam uma análise crítica de vários métodos utilizados para tratar atrasos de medições feitas de forma não-uniforme, separando-

os em métodos que fazem a fusão das medições irregulares assim que elas chegam e métodos que utilizam uma matriz de estados aumentada. Em geral, os métodos propostos para melhorar o desempenho da estimação de estados para modelos de medição mais complexos dependem da forma como o esquema de coleta dos sinais é descrito. Há trabalhos que tratam os intervalos de amostragem como processos estocásticos, como por exemplo o artigo de (Micheli e Jordan (2002)), que considera os instantes de medição como chegadas de um processo de Poisson, podendo ser utilizado para modelar uma rede de sensores não sincronizados. Outros autores estudaram o problema de estimação para uma amostragem baseada em eventos (Xue-Bo, Jing-Jing e Jia (2012), Liu et al. (2014), Zou, Wang e Zhou (2017) e Kawaguchi, Inoue e Adachi (2017)). Além da forma de modelar o instante de medição, aspectos adicionais da irregularidade amostral que influenciam na abordagem e desempenho dos métodos são: i) carimbo de tempo nas medições; ii) observações faltantes ou perda de pacotes; iii) medições fora de ordem, com defasagens únicas e/ou múltiplas; iv) *burst arrivals* (i.e. múltiplas medições chegando simultaneamente); v) representação da aleatoriedade no atraso da medição (PDF ou PMF); vi) se o atraso de tempo é múltiplo de alguma taxa-base de amostragem ou não (continuamente aleatório); vii) e se a informação é utilizada quando chega ou se há uma etapa periódica de atualização de estados.

Com uma variedade tão grande de fatores influenciando os modelos de medição, as pesquisas na área também apresentam uma vasta gama de métodos. A utilização de um espaço de estados aumentado (*state augmentation*) é uma das técnicas mais utilizadas. Nela, as medições atrasadas são tratadas através de novos estados, garantindo otimalidade da solução quando aliada ao KF tradicional (Yan et al. (2013)). Além da otimalidade, estados aumentados preservam a formulação do problema em espaços de estados, sendo uma abordagem mais simples. Para uma irregularidade muito severa ou para atrasos muito grandes, no entanto, métodos baseados em estados aumentados podem se tornar computacionalmente caros.

A estimação de estados via retrodição (Bar-Shalom (2000)) é a solução exata para tratar o problema de medições fora de ordem, mas também pode apresentar problemas computacionais dependendo da complexidade. Para reduzir o problema computacional, o trabalho de Peñarrocha, Sanchis e Romero (2012) propõe uma abordagem subótima, baseada no uso de atualizações de medições de tempo negativo (*negative-time measurement update*), que pode ser aplicado em sistemas com múltiplos sensores de diferentes taxas de amostragem; taxas de amostragem variantes no tempo; disponibilidade aleatória das

medições; diferentes atrasos variantes no tempo para cada sensor; e medições fora de ordem. No entanto, o atraso na medição precisa ser conhecido para sua utilização. Em (Julier e Uhlmann (2005)), o método de união de covariância é proposto, para o caso de atraso de tempo incerto, apresentando um custo benefício interessante. Se, apesar de não uniforme, a amostragem apresentar um comportamento periódico, a técnica de *lifting* pode ser aplicada, como nos trabalhos de Sheng, Chen e Shah (2002), Li, Shah e Xiao (2005) e Liang, Chen e Pan (2009). Em (Xue-Bo, Jing-Jing e Jia (2012)) o problema de estimação com amostragem irregular é transformado em um problema de estimação com parâmetros variantes no tempo, por meio da transformada inversa de Laplace. Dessa forma, cada intervalo de tempo de amostragem é incorporado ao sistema, por meio do cálculo de novos parâmetros do sistema discretizado.

### *1.2 Formulação do problema*

Apresentação matemática do problema, de forma ampla. Descrever as premissas adotadas.

### *1.3 Objetivos*

1 frase para o objetivo geral Objetivos específicos

### *1.4 Estrutura da Dissertação*

## 2 Conclusão

## Referências

- ANXI, Y. et al. A Unified Out-of-sequence Measurements Filter. In: *IEE International Radar Conference*. [S.l.: s.n.], 2005. v. 00, n. C. Citado na página 3.
- BAR-SHALOM, Y. Update with out-of-sequence measurements in tracking: Exact solution. *Proceedings of SPIE*, v. 4048, n. 3, p. 769–778, 2000. Citado na página 4.
- BAR-SHALOM, Y.; Rong Li, X.; KIRUBARAJAN, T. *Estimation with Applications to Tracking and Navigation: Theory Algorithms and Software*. [S.l.]: John Wiley & Sons, Inc, 2001. 548 p. Citado na página 2.
- FATEHI, A.; HUANG, B. Kalman filtering approach to multi-rate information fusion in the presence of irregular sampling rate and variable measurement delay. *Journal of Process Control*, Elsevier Ltd, v. 53, p. 15–25, 2017. Citado na página 3.
- GOPALAKRISHNAN, A.; KAISARE, N. S.; NARASIMHAN, S. Incorporating delayed and infrequent measurements in Extended Kalman Filter based nonlinear state estimation. *Journal of Process Control*, v. 21, p. 119–129, 2010. Citado na página 3.
- HALL, D. L.; LLINAS, J. An introduction to multisensor data fusion. *Proceedings of the IEEE*, v. 85, n. 1, p. 6–23, 1997. Citado 2 vezes nas páginas 2 e 3.
- JING, Z.; PAN, H.; QIN, Y. Current progress of information fusion in China. *Chinese Science Bulletin*, v. 58, n. 36, p. 4533–4540, dec 2013. Citado na página 3.
- JULIER, S. J.; UHLMANN, J. K. Fusion of time delayed measurements with uncertain time delays. In: *Proceedings of the 2005 American Control Conference*. [S.l.: s.n.], 2005. p. 4028–4033. Citado na página 5.
- KAWAGUCHI, T.; INOUE, M.; ADACHI, S. State Estimation under Lebesgue Sampling and an Approach to Event-Triggered Control. *SICE Journal of Control, Measurement, and System Integration*, v. 10, n. 3, p. 259–265, 2017. Citado na página 4.
- KHALEGHI, B. et al. Multisensor data fusion: A review of the state-of-the-art. *Information Fusion*, Elsevier B.V., v. 14, n. 1, p. 28–44, 2013. Citado na página 3.
- LI, W.; SHAH, S. L.; XIAO, D. Kalman Filters for Non-Uniformly Sampled Multirate Systems. In: *IFAC Proceedings Volumes*. [S.l.]: IFAC, 2005. v. 38, n. 1, p. 99–104. Citado na página 5.
- LIANG, Y.; CHEN, T.; PAN, Q. Multi-rate optimal state estimation. *International Journal of Control*, v. 82, n. 11, p. 2059–2076, 2009. Citado na página 5.
- LIU, Q. et al. A survey of event-based strategies on control and estimation. *Systems Science and Control Engineering*, v. 2, n. 1, p. 90–97, dec 2014. Citado na página 4.
- MICHELI, M.; JORDAN, M. I. Random sampling of a continuous-time stochastic dynamical system. In: *Proc. of the 15th International Symposium on the Mathematical Theory of Networks and Systems*. [S.l.: s.n.], 2002. p. 1–15. Citado 2 vezes nas páginas 3 e 4.



MOAYEDI, M.; FOO, Y. K.; SOH, Y. C. Filtering for networked control systems with single/multiple measurement packets subject to multiple-step measurement delays and multiple packet dropouts. *International Journal of Systems Science*, v. 42, n. 3, p. 335–348, 2011. Citado na página 3.

PEÑARROCHA, I.; SANCHIS, R.; ROMERO, J. A. State estimator for multisensor systems with irregular sampling and time-varying delays. *International Journal of Systems Science*, v. 43, n. 8, p. 1441–1453, 2012. Citado na página 4.

SCHENATO, L. et al. Foundations of Control and Estimation Over Lossy Networks. *Proceedings of the IEEE*, v. 95, n. 1, p. 163–187, jan 2007. Citado na página 3.

SHENG, J.; CHEN, T.; SHAH, S. L. Generalized predictive control for non-uniformly sampled systems. *Journal of Process Control*, v. 12, p. 875–885, 2002. Citado na página 5.

TEIXEIRA, B. O. S. *Constrained state estimation for linear and nonlinear dynamic systems*. Tese (Doutorado) — Universidade Federal de Minas Gerais, 2008. Citado na página 2.

WILLNER, D.; CHANG, C. B.; DUNN, K. P. Kalman filter algorithms for a multi-sensor system. In: *IEEE Conference on Decision and Control including the 15th Symposium on Adaptive Processes*. [S.l.: s.n.], 1976. v. 15, p. 570–574. Citado na página 3.

XUE-BO, J.; JING-JING, D.; JIA, B. Target Tracking of a Linear Time Invariant System Under Irregular Sampling. *International Journal of Advanced Robotic Systems*, v. 9, 2012. Disponível em: <http://journals.sagepub.com/doi/pdf/10.5772/54471>. Citado 2 vezes nas páginas 4 e 5.

YAN, L. et al. State estimation for a kind of non-uniform sampling dynamic system. *International Journal of Systems Science*, v. 44, n. 10, p. 1913–1924, oct 2013. Citado na página 4.

ZOU, L.; WANG, Z.-D.; ZHOU, D.-H. Event-based Control and Filtering of Networked Systems: A Survey. *International Journal of Automation and Computing*, v. 14, n. 3, p. 239–253, 2017. Citado 2 vezes nas páginas 3 e 4.